

Relatório EP2 - Tradução Automática de Baixo Recurso

Vitor Voigt Gava (NUSP: 14611842)

1 Introdução

Este trabalho investiga a viabilidade de traduzir entre português (`por_Latn`) e Tupi Antigo representado por `grn_Latn`, um par linguístico para o qual há não muitos recursos paralelos disponíveis.

A investigação foi conduzida em dois regimes complementares. No regime *zero-shot*, o modelo pré-treinado foi utilizado diretamente, avaliando sua capacidade intrínseca de generalização para um par de baixa presença. Já no regime *few-shot*, foi realizado fine-tuning supervisionado com LoRA aplicado separadamente para cada direção de tradução (PT $\rightarrow$ Tupi e Tupi $\rightarrow$ PT). As traduções produzidas foram avaliadas por métricas automáticas padronizadas (BLEU, chrF1, chrF3), complementadas por uma análise qualitativa envolvendo as dez melhores e dez piores sentenças segundo BLEU por frase.

Os resultados obtidos permitem comparar de forma direta o desempenho do modelo pré-treinado com sua versão adaptada, revelando não apenas as limitações do regime zero-shot, mas também a natureza assimétrica dos ganhos proporcionados pelo fine-tuning. Embora o ajuste fino produza melhorias em termos quantitativos, sobretudo no aumento expressivo da métrica BLEU, a análise qualitativa indica que esse ganho ocorre às custas de certa degradação linguística, manifestada em previsões menos estáveis, repetições anômalas e comportamentos degenerados em algumas frases.

2 Catálogo com descrições dos arquivos enviados

- `ep2.ipynb`: Notebook com o pipeline (células de pré-processamento, inferência, fine-tuning, avaliação).
- `pt2tupi_fewShot_best10.csv`: top10 traduções pt→tupi (few-shot) ordenadas por BLEU.
- `pt2tupi_fewShot_worst10.csv`: bottom10 traduções pt→tupi (few-shot).
- `pt2tupi_zeroShot_best10.csv`: top10 traduções pt→tupi (zero-shot).
- `pt2tupi_zeroShot_worst10.csv`: bottom10 traduções pt→tupi (zero-shot).
- `tupi2pt_fewShot_best10.csv`: top10 traduções tupi→pt (few-shot).
- `tupi2pt_fewShot_worst10.csv`: bottom10 traduções tupi→pt (few-shot).
- `tupi2pt_zeroShot_best10.csv`: top10 traduções tupi→pt (zero-shot).
- `tupi2pt_zeroShot_worst10.csv`: bottom10 traduções tupi→pt (zero-shot).
- `results_zero_shot.txt`: métricas do regime zero-shot (BLEU, chrF1, chrF3).
- `results_few_shot.txt`: métricas do regime few-shot (BLEU, chrF1, chrF3) e logs.
- `pt2tupi_fewShot_fixed.csv`: arquivo com corpus teste traduzido pt→tupi (few-shot) formatado.
- `tupi2pt_fewShot_fixed.csv`: arquivo com corpus teste traduzido tupi→pt (few-shot) formatado.
- `tupi2pt_zeroShot_fixed.csv`: arquivo com corpus teste traduzido tupi→pt (zero-shot) formatado.
- `pt2tupi_zeroShot_fixed.csv`: arquivo com corpus teste traduzido pt→tupi (zero-shot) formatado.
- `test_fixed.csv`: corpus de tese processado.
- `train_fixed.csv`: corpus de treino processado.
- `validation_fixed.csv`: corpus de validação processado.
- `Cópia de portugues-guarani-tupi antigo.xlsx`: corpus original fornecido no enunciado.
- `nllb-ft-pt2tupi/`: diretório com modelo treinado (PT→Tupi).
- `nllb-ft-tupi2pt/` — diretório com modelo treinado (Tupi→PT).

3 Descrição do corpus

O corpus paralelo utilizado neste trabalho (colunas `portugues` e `tupi`) encontra-se disponível no repositório:

https://github.com/CalebeRezende/oldtupi_dataset/blob/main/C%C3%B3pia%20de%20portugues-guarani-tupi%20antigo.xlsx

As operações de limpeza e preparação realizadas incluem:

- Remoção de conteúdo entre parênteses, incluindo os parênteses;
- Normalização de apóstrofes na forma unificada (');
- Remoção de aspas exteriores inconsistentes e padronização das linhas CSV no seguinte formato: "frase em pt","frase em tupi";
- Substituição de ã por nh no Tupi;
- Normalização Unicode (NFC) e remoção de espaços duplicados;
- Embaralhamento do dataframe e divisão em `train/validation/test` (70/15/15).

Os corpus processados se encontram contidos nos arquivos: `test_fixed.csv`, `validation_fixed.csv` e `train_fixed.csv`.

4 Descrição da Metodologia zero-shot e few-shot

Nesta seção descrevemos o fluxo experimental adotado nas avaliações *zero-shot* e *few-shot* (fine-tuning) entre Português (`por_Latn`) e a variedade identificada como “Tupi Antigo” (`grn_Latn`). Incluímos as etapas de pré-processamento, as decisões de modelagem e treino, a estratégia de seleção de checkpoints e o protocolo de avaliação automática.

4.1 Resumo do procedimento

O pipeline segue as etapas: (i) limpeza e normalização do corpus paralelo; (ii) divisão em `train/validation/test` (70% / 15% / 15%); (iii) inferência *zero-shot* com o modelo pré-treinado; (iv) fine-tuning *few-shot* usando LoRA (PEFT) em modelos separados para cada direção (PT→Tupi e Tupi→PT); (v) geração das previsões sobre o split de teste; (vi) avaliação automática (sacreBLEU, chrF₁, chrF₃) e seleção das 10 melhores/piores sentenças por BLEU.

4.2 Justificativas Metodológicas e Escolhas de Modelagem

A opção por treinar dois modelos independentes, um exclusivo para a direção PT→Tupi e outro para Tupi→PT, decorre de precauções teóricas sobre o treinamento bidirecional. Embora, em princípio, um único modelo multilíngue possa aprender ambas as direções simultaneamente, foi receado que o treinamento bidirecional introduzisse uma mistura indesejada de gradientes de forma que as atualizações provenientes de uma direção interferissem negativamente na outra, resultando numa potencial degradação de métricas. Separar os modelos precaveria essa competição interna e permitiria que cada direção seja

otimizada isoladamente, ajustando-se de maneira mais sensível às propriedades específicas de cada tarefa.

A escolha do modelo `facebook/nllb-200-distilled-600M` foi motivada por uma combinação de fatores práticos e linguísticos. Em termos de cobertura, o NLLB inclui suporte nativo ao código `grn_Latn`, ao contrário do mBART-50, que não contempla essa variante e exigiria modificações no vocabulário para lidar com o Tupi Antigo. Além disso, a versão *distilled-600M* é mais leve que os modelos completos, o que foi decisivo dado que o treinamento precisou ocorrer integralmente em CPU devido a problemas de compatibilidade entre a GPU disponível e o PyTorch, tornando impraticável o uso de arquiteturas maiores. Por fim, o NLLB apresenta integração com métodos de adaptação eficiente, como PEFT e LoRA, permitindo reduzir drasticamente o número de parâmetros treináveis e tornar o fine-tuning viável em hardware limitado, sem comprometer a capacidade de especialização do modelo.

4.3 Metodologia Zero-shot

No regime *zero-shot*, o modelo `facebook/nllb-200-distilled-600M` é carregado diretamente em seu estado pré-treinado, sem qualquer ajuste específico ao par Português–Tupi. Utiliza-se o tokenizador nativo do NLLB, configurado com `src_lang` e `tgt_lang` apropriados para cada direção, permitindo que o próprio modelo aplique os mecanismos internos de seleção de idioma. Em seguida, todo o conjunto de teste é traduzido nas duas direções (PT→Tupi e Tupi→PT) utilizando a função de geração padrão do modelo com um limite de 128 tokens. Como essa etapa é computacionalmente intensiva, especialmente na CPU, as traduções são geradas uma única vez e salvas em arquivos `.csv` para evitar recomputação posterior.

Após a tradução, aplica-se uma limpeza mínima das saídas (*post-processing*) para remover artefatos, seguido do cálculo das métricas de avaliação. Usam-se dois tipos de métricas: (i) métricas corpus-level (BLEU, CHRF1 e CHRF3), avaliando qualidade global; e (ii) métricas sentence-level, calculadas com BLEU da biblioteca `sacrebleu`, permitindo ordenar todas as frases traduzidas por qualidade e extrair os 10 melhores e 10 piores exemplos em cada direção. Esses resultados são exportados em arquivos separados (`best10` e `worst10`), utilizados posteriormente para análise qualitativa do modelo pré-treinado.

4.4 Metodologia Few-shot

O regime few-shot consistiu no ajuste fino do modelo `facebook/nllb-200-distilled-600M`, realizado separadamente para cada direção de tradução (PT → Tupi e Tupi → PT). Para cada direção, definiu-se um tokenizer distinto e aplicou-se um pré-processamento específico, garantindo o alinhamento correto entre entradas e rótulos tokenizados. Em seguida, cada modelo foi envolvido por um adaptador LoRA, configurado com $r = 16$, $\alpha = 32$ e modificação restrita às projeções de atenção (`q_proj` e `v_proj`). Essa adaptação reduziu drasticamente o número de parâmetros treináveis, permitindo a execução completa do fine-tuning em CPU, já que limitações de compatibilidade impediram o uso estável de GPU.

O treinamento foi configurado para cinco épocas e conduzido com *learning rate* 5×10^{-5} , *weight decay* 0.01, *batch size* igual a 4 e mecanismo de *early stopping* com paciência de duas épocas. Embora o `Seq2SeqTrainer` permita selecionar automaticamente o melhor modelo, por um descuido acabou-se por manter o critério padrão de menor *validation loss*,

em vez de maior BLEU, de modo que cada época gerasse um checkpoint. Assim, o processo de treino retornou somente as métricas do último modelo, mas tornou possível selecionar posteriormente, de forma manual, o checkpoint que de máximo BLEU no conjunto de validação, sendo essa a métrica realmente relevante para a tarefa de tradução.

As Tabelas 1 e 2 apresentam os resultados por época para as duas direções. Em ambos os casos, observa-se que o BLEU máximo não coincide com a época de menor *validation loss*, reforçando a necessidade da seleção manual do melhor checkpoint.

Tabela 1: Resultados por época — PT $\rightarrow$ Tupi

Época	Training Loss	Validation Loss	BLEU
1	4.647800	4.233756	0.355717
2	4.291000	3.935557	0.470439
3	4.040600	3.795506	0.446001
4	3.979800	3.720820	0.454227
5	3.912500	3.695590	0.467424

Tabela 2: Resultados por época — Tupi $\rightarrow$ PT

Época	Training Loss	Validation Loss	BLEU
1	3.562400	3.290540	0.659844
2	3.417500	3.165364	0.988228
3	3.297200	3.092322	0.748181
4	3.203600	3.055538	0.803171
5	3.211100	3.041938	0.796633

Após o treinamento, cada modelo selecionado (o de maior BLEU em sua respectiva direção) foi utilizado para traduzir integralmente o conjunto de teste. As traduções foram exportadas para os arquivos correspondentes, avaliadas em BLEU, chrF1 e chrF3, e então realizada a seleção das dez melhores e dez piores traduções em cada direção.

5 Análise dos resultados das métricas automáticas

A seguir são apresentadas as métricas obtidas para ambos os regimes de avaliação conforme registrado os arquivos `results_zero_shot.txt` e `results_few_shot.txt`. A Tabela resume, lado a lado, os valores de BLEU, chrF1 e chrF3 para as duas direções de tradução, permitindo comparar diretamente o impacto do fine-tuning sobre o desempenho do modelo.

Tabela 3: Comparação das métricas Zero-shot e Few-shot

Direção	Zero-shot			Few-shot		
	BLEU	chrF1	chrF3	BLEU	chrF1	chrF3
PT → Tupi	0.1190	11.9806	13.2296	0.4611	6.8467	9.1878
Tupi → PT	0.2404	12.3135	12.0392	0.8308	13.9667	13.8709

Do ponto de vista de BLEU, observa-se um ganho em ambas as direções após o fine-tuning: de 0.1190 para 0.4611 na direção PT → Tupi e de 0.2404 para 0.8308 na direção Tupi → PT. Esse aumento era esperado, pois o BLEU privilegia coincidências exatas de n-gramas, algo que o fine-tuning tende a reforçar ao alinhar mais explicitamente o modelo ao estilo e vocabulário do corpus paralelo. Assim, mesmo com um corpus relativamente pequeno, o modelo passa a produzir sequências mais próximas das referências, resultando em um aumento dessa métrica.

Os comportamentos de chrF1 e chrF3, entretanto, diferem entre as duas direções. Para PT → Tupi, ambos os valores diminuem após o treinamento, enquanto para Tupi → PT eles aumentam. Isso sugere uma assimetria entre as tarefas: gerar Tupi Antigo parece induzir o modelo, após o fine-tuning, a produzir formas mais padronizadas e com maior coincidência lexical global (beneficiando o BLEU), porém potencialmente reduzindo a similaridade baseada em caracteres quando comparada à grande variabilidade morfológica e ortográfica presente no corpus de referência. No sentido inverso, gerar português a partir de Tupi tende a produzir frases com maior estabilidade ortográfica e menor variação morfológica, o que naturalmente beneficia métricas baseadas em caracteres, explicando o ganho simultâneo em BLEU, chrF1 e chrF3 na direção Tupi → PT.

6 Análise linguística qualitativa

A seguir são apresentadas duas tabelas com traduções selecionadas com melhores e piores resultados segundo o ranqueamento por BLEU, tanto no regime zero-shot quanto no few-shot. Nesta seção, analisamos exclusivamente o conteúdo linguístico das previsões, buscando compreender padrões de acerto, desvios e erros característicos de cada regime.

Tabela 4: Resultados Zero-shot: melhores e piores traduções

Zero-shot		
Tradução Real	Tradução prevista	BLEU
PT → Tupi — Top 10		
pé rupi	tape rupi	49.99
nde rera	nde réra	49.99
îaru!	Jahupyty chupe!	27.52
ereké-pipó eîupa?	Reñot añete?	27.52
nde raûsuba poepyka	Ombohováivo nde rayhupápe	27.52
t'aîmopóne nde nhe'enga	Ajapóta nde ñe'	27.52
umãmepe sekóû?	Moõpa oiko?	27.52
y anh	y sa'i ñembyaty	27.52
nde ra'y-pupuka	nde semino ejaculado	27.52
anh ûi!	Ha'e añete!	27.52
PT → Tupi — Bottom 5		
ou bé senha'pepó t'omoîy xe renondé	Ogueru avei nde ygarata ha'e osê	0.0
	haguã che renondépe	
itá karamemûã pupé i nongi	Petei ita guýpe omoî hikuái	0.0
anhopan	Aheja chupe	0.0
xe tegûam	Che areko petei mba'e	0.0
aîpitupuku	Che akãra'ã	0.0
Tupi → PT — Top 10		
Tragamo-lo!	Olá!	49.99
Afasta-te!	Abre!	49.99
Eu não enxergo	não olha	30.32
água sem mistura	água doce	30.32
Nós somos numerosos	nós somos	30.32
Tragamo-lo!	Tão rápido!	27.52
braço de rio	cabeça de água	27.52
Jazo de bruços	abasteceu-se de um	27.52
Meu senhor!	é 'a!	27.52
"Sim, esses me satisfazem"	"Sim, eu estou esperando"	21.36
Tupi → PT — Bottom 10		
"Ah, se viesse!"	terrute vem	0.0
Eu sou mocho	por causa da luz	0.0
Eu sou rechonchudinho	É um pouco	0.0
o que proclama suas palavras	a sua cabeça está longe	0.0
Arranquei-lhe a casca	eu tenho-'ok	0.0
desde minha vinda	xe rura agüerabé	0.0
Veio também sua panela...	veio sem dúvida em frente ao xe	0.0
Aparei-o	em um banho	0.0
Eu tenho peçonha	é um lugar	0.0
Tinjo as pernas	eu tenho muito tempo	0.0

Tabela 5: Resultados Few-shot: melhores e piores traduções

Few-shot		
Tradução Real	Tradução prevista	BLEU
PT → Tupi — Top 10		
kó xe ypy	kó xe nye'	55.03
i popebusu	i îaîba	50.00
xe abangaîba	xe îandêiaî...	50.00
i mongu'ipyra	i îaîba	50.00
xe nambi-asyk	xe apysá-pyrá	50.00
xe 'anga	xe apytu'u	50.00
i 'a	i abá	50.00
xe atimandápe	xe moîasé	50.00
i ma'enduar	i îe'îaî	50.00
xe roÿpyre'yma	xe moîaî	50.00
PT → Tupi — Bottom 5		
tera'ute oú	aîeîaîaîaîaî!	0.0
erekopîasópe domingo ...	ereîmoîarûûû...	0.0
aîpé-'ok	aîmoîaîaî	0.0
anhopan	aîe'îa	0.0
aîpitupuku	xe rapy	0.0
Tupi → PT — Top 10		
Eu sou airoso	Eu sou	60.65
Eu sou pardo	Eu sou negro	55.03
Eu sou fedorento	Eu sou teu	55.03
Eu tenho diarreia	Eu tenho medo	55.03
Eu estou atolado	Eu estou deitado	55.03
Afasta-te!	Abre-o!	50.00
Não sei	Não pecar	50.00
Não pode alguém casar-se...?	Não pode alguém casar-se...?	47.75
"Eu sou cristão. . ."	"Eu sou cristão, meu pai"	43.01
Não nos queremos bem	Não nos afaste	39.43
Tupi → PT — Bottom 10		
"Hei de levar todos..."	A minha alma está em minha boca	0.0
Vê minha doença...	Que o meu Senhor me dê o seu nome	0.0
Em terra não os fazendo transformar	O mar é o que faz com que ele se torne	0.0
Eu enivre	minha mulher	0.0
"Ah, se viesse!"	A gente veio	0.0
o que proclama suas palavras	A sua boca está longe	0.0
Arranquei-lhe a casca	Eu sou o que é	0.0
desde minha vinda	Eu sou o que me faz cair	0.0
Aparei-o	Eu vou	0.0
Tinjo as pernas	Eu estou muito	0.0

“pé rupi” → “tape rupi”
 “nde rera” → “nde réra”

“xe ater” → “Che niko che mbarakaja”
 “i nhe’enga mombegûara” → “ohesapukáva iñe”

"xe abangai̯ba" → *"xe iandéiaiaiaiaiaiaiaiaiaiaiaiaiaiaiaiaia..."*

[illegible]

Apesar desses problemas, as melhores traduções few-shot revelam avanços qualitativos significativos em relação ao zero-shot. Muitas previsões tornam-se mais alinhadas ao sentido original, com escolhas lexicais mais apropriadas e construções sintaticamente próximas às usadas no corpus. Em contrapartida, o modelo demonstra vulnerabilidade quando exposto a entradas longas, irrestritas ou pouco frequentes, nas quais frequentemente responde com repetições, truncamentos ou formas inventadas.

7 Conclusões e Limitações

A análise realizada ao longo deste relatório evidencia que o modelo NLLB, apresenta capacidade inicial limitada para lidar com o par Português–Tupi no regime *zero-shot*. Os resultados qualitativos revelaram que, embora algumas estruturas curtas e de alta frequência sejam traduzidas de forma plausível, o modelo frequentemente recorre a produções genéricas ou traduções semanticamente desvinculadas. O fine-tuning via LoRA altera esse comportamento: o modelo passa a exibir maior aderência morfosintática ao domínio, resultando em traduções de melhor qualidade geral. Em termos qualitativos, o few-shot corrigiu inadequações sistemáticas do zero-shot, especialmente no mapeamento de expressões menos comuns e construções sintáticas mais complexas.

Entretanto, a análise qualitativa também revelou limitações claras do ajuste fino. Apesar do ganho global, o modelo fine-tunado gerou saídas altamente degeneradas em alguns casos, como sequências artificiais com padrões repetitivos ou cadeias de sílabas sem sentido linguístico. Essas degradações apareceram tanto entre as melhores quanto entre as piores previsões, sugerindo que o modelo, ao se especializar no corpus reduzido, ocasionalmente entra em estados de repetição típica de modelos de linguagem sobreajustados. Além disso, a ausência de mecanismos explícitos de regularização mais fortes, a limitação computacional (treinamento em CPU) e o tamanho reduzido do conjunto de treinamento podem ter contribuído para tais comportamentos instáveis.

Por fim, embora o few-shot tenha superado o zero-shot em coerência linguística, ambos os regimes representam aproximações imperfeitas diante da complexidade histórica e fonológica do Tupi Antigo. A ausência de padronização de acentos e a escassez de dados paralelos dificultam o aprendizado de correspondências mais refinadas. Assim, os resultados obtidos devem ser interpretados considerando tais limitações estruturais.